





Abd Rahman



Data Acquisition

• Data Acquisition merupakan nama lain dari pengumpulan data.



Sumber Data

- Data Primer
 - Survey, Sensus
 - Eksperimen/Percobaan
 - Scraping, Crawling
- Data Skunder: data yang bersumber dari pihak ketiga



Scraping dan Crawling

- Crawling merupakan teknik mengumpulkan data pada sebuah website dengan memasukkan Uniform Resource Locator (URL)
- Crawling biasanya menggunakan Application Programming Interface (API) sebagai jalur komunikasi dalam mendapatkan data.
- Scraping merupakan teknik mengumpulkan data pada sebuah website melalui proses ektraksi informasi menggunakan Hypertext Transfer Protocol (HTTP).
- Scrapingbiasanya perlu mengetahui element HTML ataupun XML pada sebuah website



Legalitas Scraping

- Scrapping secara umum (minimal) tidak etis (bisa jadi ilegal). Mengapa? karena scraping mirip DDOS attack yang akan memberatkan server atau bahkan membuat server berhenti berfungsi normal.
- Program scraping juga memungkinkan akan mengakses data yang tidak dimaksudkan untuk konsumsi publik.
- Satu-satunya saat dimana scraping boleh dilakukan adalah saat sang pelaku/programmer menghormati "robots.txt" yang telah diberikan oleh web administrator.
- Menggunakan API (Application Program Interface) yang diberikan oleh provider (website/medsos) lalu melakukan crawling.
- Yakinkan untuk membaca ToS (Terms of Sevice) dengan baik.





- Crawling menggunakan package tweepy di python
- Tweepy merupakan package python untuk mengakses API Twitter resmi
- Tweepy perlu mendaftar sebagai developer dan dan mendapatkan kunci dari Twitter
- Scrapping menggunakan package twint di python
- Twint tidak menggunakan API Twitter Resmi

See More:

- Tweepy documentation: https://docs.tweepy.org/en/latest/
- Twint documentation: https://github.com/twintproject/twint/wiki





- Performa: twint jauh lebih lambat untuk mendapatkan data dibandingkan tweepy
- **Limitasi: tweepy** bergantung pada limitasi **Twiiter API,** seperti jumlah tweet yang bisa dikumpulkan terbatas.





- Untuk bisa menggunakan package tweepy kita harus mendaftar terlebih dahulu di Twitter Developer
- Dari website tersebut akan didapatkan semacam key yang harus dimasukan ke program

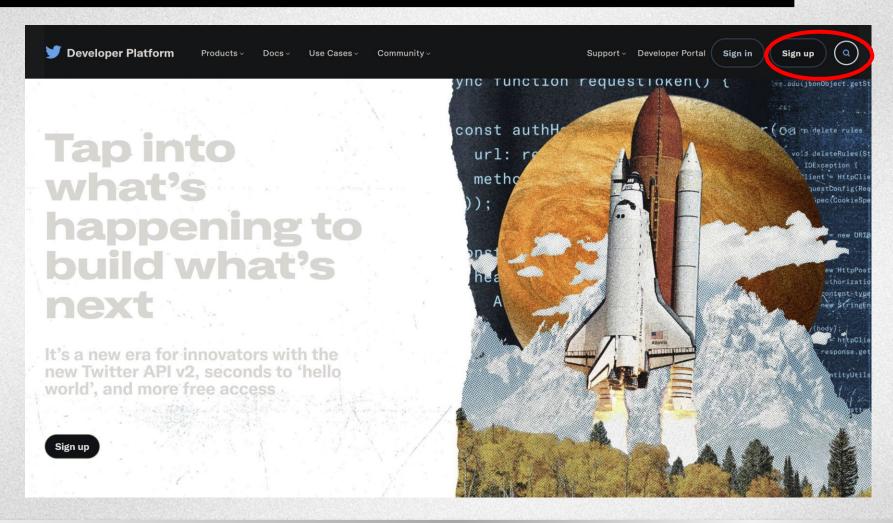




Langkah-langkah untuk mendapatkan key dan token dari twitter:

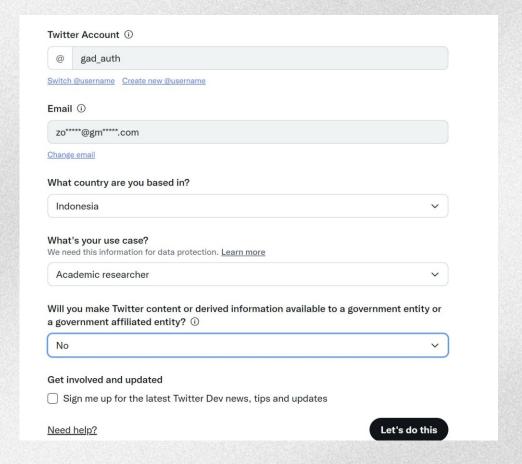
- I. Login ke twitter (buat bila belum ada dengan menyertakan nomor hp)
- 2. Registrasi sebagai developer: https://developer.twitter.com/en
- 3. Klik Sign Up







- 4. Isi form sesuai dengan kebutuhan
- 5. Klik Let's do this





Docs V Communi

- 6. Centang Accept Terms & Conditions
- 7. Klik Submit

Developer agreement & policy

Developer Agreement

Effective: January 19, 2023

This Twitter Developer Agreement ("Agreement") is made between you (either an individual or an entity, referred to herein as "you") and Twitter (as defined below) and governs your access to and use of the Licensed Material (as defined below). Your use of Twitter's websites, SMS, APIs, email notifications, applications, buttons, embeds, ads, and our other covered services is governed by our general Terms of Service and Privacy Policy.

PLEASE READ THE TERMS AND CONDITIONS OF THIS AGREEMENT CAREFULLY, INCLUDING ANY LINKED TERMS REFERENCED BELOW, WHICH ARE PART OF THIS LICENSE AGREEMENT. BY USING THE LICENSED MATERIAL, YOU ARE AGREEING THAT YOU HAVE READ,

Accept Terms & Conditions

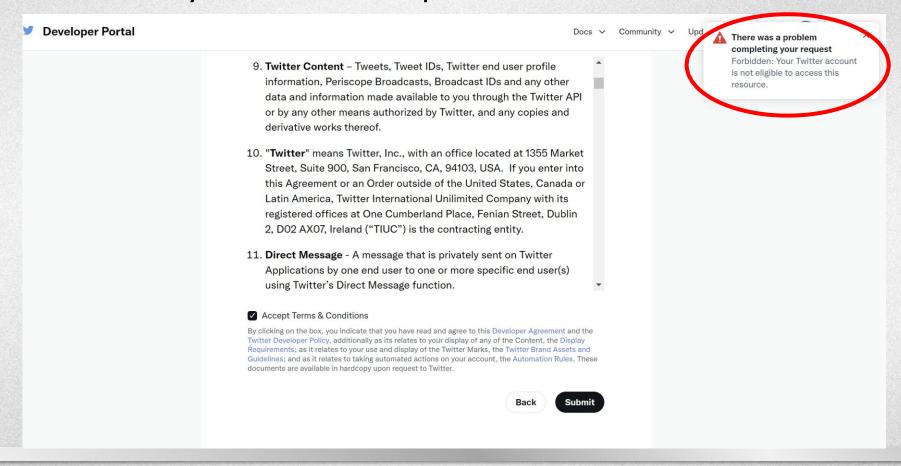
By clicking on the box, you indicate that you have read and agree to this Developer Agreement and the Twitter Developer Policy, additionally as its relates to your display of any of the Content, the Display Requirements; as it relates to your use and display of the Twitter Marks, the Twitter Brand Assets and Guidelines; and as it relates to taking automated actions on your account, the Automation Rules. These documents are available in hardcopy upon request to Twitter.

Back

Submit

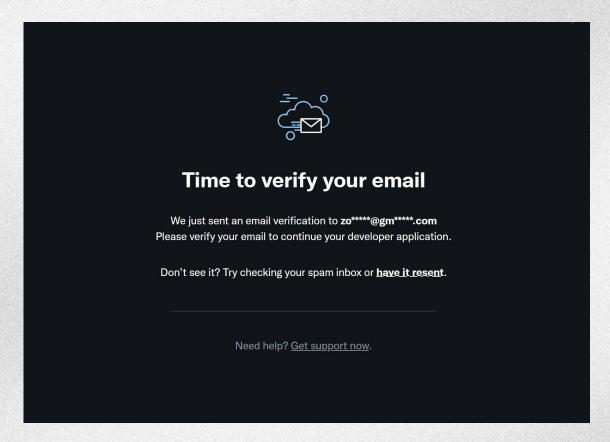


Jika belum menyertakan nomor telpon di akun twiiter maka akan muncul error



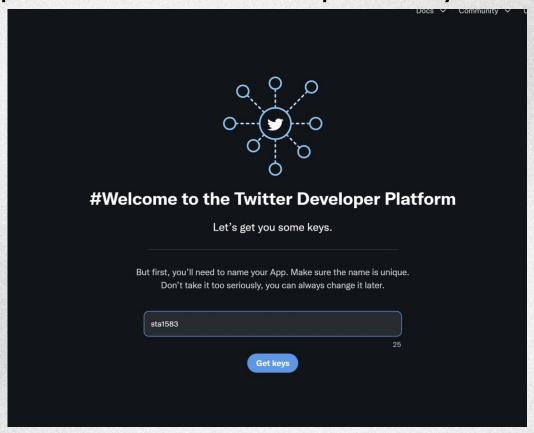


8. Periksa Email anda dan kemudian konfirmasi melalui email anda





9. Tuliskan nama aplikasi anda untuk mendapatkan key:





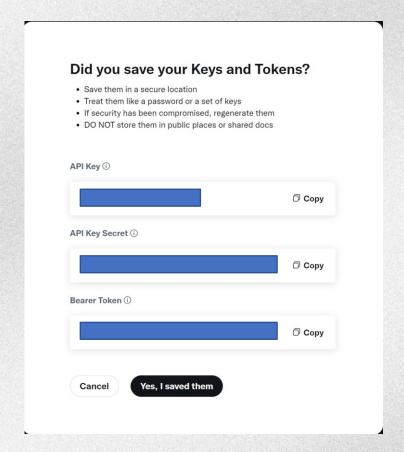
10. Simpan informasi ini (api key, api key secret, bearer token) di tempat yang aman

(notepad/screenshoot/dll)

Here are your keys.	
These verify and allow you to make requests to the Twitter API.	
For security, this will be the last time we'll fully display the Secret. Save them in a secure location Treat them like a password or a set of keys If security has been compromised, regenerate them DO NOT store them in public places or shared docs	
API Key ①	
	🗇 Сору
API Key Secret ①	
	🗇 Сору
Bearer Token ①	
	🗇 Сору
View sample Apps	Dashboard



- 11. Klik dashboard
- 12. Klik Yes, I saved them
- 13. Selesai







- Search queries digunakan untuk mendapatkan tweet yang kita inginkan
- Search queries terdiri dari keyword dan konjungsi-operator seperti is:retweet



Search queries untuk Twitter

- Contoh Search queries: **from:pemersatubangsa**berarti kita akan mendapatkan semua tweet dari akun **pemersatubangsa**
- Contoh Search queries: corona coronavirus covid-19 berarti kita akan mendapatkan tweet yang memuat kata corona, coronavirus dan covid-19. "Spasi" diantara kata berarti operator logika AND.
- Contoh Search queries: **from:pemersatubangsa –is:retweet** berarti kita akan mendapatkan semua tweet dari akun **pemersatubangsa** tanpa **retweet**. Operator **is:retweet** berarti me-filter tweet yang berupa retweet dan operator "-" berarti menegasikan kondisi.



Search queries untuk Twitter

- Contoh Search queries: covid-19 has:geo berarti kita akan mendapatkan tweet yang memuat kata covid-19 dan terdapat data geo didalamnya
- Contoh Search queries: **from:pemersatubangsa has:images** berarti kita akan mendapatkan semua tweet dari **pemersatubangsa** yang terdapat gambar didalamnya.
- Contoh Search queries: **covid-19 lang:en** berarti kita akan mendapatkan tweet yang memuat kata **covid-19** dan berbahasa inggris.



Operator	Description
\$	Matches any Tweet that contains the specified 'cashtag'.
place	Matches Tweets tagged with the specified location or Twitter place ID
place_country	Matches Tweets where the country code associated with a tagged place/location matches the given ISO alpha-2 character code
point_radius	Matches against the place.geo.coordinates object of the Tweet when present, and in Twitter, against a place geo polygon, where the Place polygon is fully contained within the defined region
bounding_box	Matches against the place.geo.coordinates object of the Tweet when present, and in Twitter, against a place geo polygon, where the place polygon is fully contained within the defined region
-is:nullcast	removes Tweets created for promotion only on ads.twitter.com that have a "source":"Twitter for Advertisers (legacy)" or "source":"Twitter for Advertisers"
has:cashtags	Matches Tweets that contain a cashtag symbol (with a leading '\$' character. For example, \$tag)
has:geo	Matches Tweets that have Tweet-specific geolocation data provided by the Twitter user
bio	Matches a keyword within the Tweet publisher's user bio name
bio_name	Matches a keyword within the Tweet publisher's user bio name
bio_location	Matches Tweets that are published by users whose location contains the specified keyword or phrase





Referensi

- Teknik Pengumpulan Data Sekunder dengan Web Crawling (dqlab.id)
- Perbedaan Antara Crawling dan Scraping | by Dede Brahma | Medium
- taudata Analytics: Apakah scraping website/media sosial diperbolehkan?
- What Python package is best for getting data from Twitter? Comparing Tweepy and Twint. | by JP Hwang | Towards Data Science
- https://github.com/twitterdev/getting-started-with-the-twitter-api-v2-for-academic-research/blob/main/modules/5-how-to-write-search-queries.md
- How to Access Data from the Twitter API using Tweepy (Python) | by Michael
 Galarnyk | Towards Data Science